

# Predicción diaria del riesgo de incendio en la Región Pampeana mediante XGBoost optimizado por *Sparrow Search Algorithm*, con calibración de probabilidades y arquitectura *lakehouse* de extremo a extremo

Julián Mendelewicz  
Trabajo final de diplomatura

Julio de 2026

## Resumen

Los incendios de vegetación constituyen una amenaza recurrente para la producción agropecuaria y los ecosistemas de la Región Pampeana argentina. Este trabajo presenta un sistema completo de predicción diaria de ocurrencia de fuego que integra datos satelitales y meteorológicos de múltiples fuentes sobre una grilla regular de 2.266 celdas de 0,25°, cubriendo el período 2022–2024. Siguiendo el marco propuesto por Wang *et al.* [1] para la provincia de Guangdong, se entrenó un clasificador XGBoost cuyos hiperparámetros fueron optimizados mediante el *Sparrow Search Algorithm* (SSA), incorporando el sistema canadiense FWI adaptado al hemisferio sur, variables topográficas, antrópicas, de vegetación y de autocorrelación espacial. Sobre un conjunto de prueba temporal estrictamente posterior al entrenamiento (416.024 observaciones, prevalencia 3,13 %), el modelo final alcanzó un AUC-ROC de 0,897 y una precisión media (AP) de 0,304, superando en 2,4 veces a la persistencia espacial y en 8,7 veces a un modelo basado únicamente en el índice FWI. El desarrollo se condujo con criterio de auditoría permanente. Se documentan cuatro iteraciones del modelo, tres fugas de información detectadas y corregidas, la recalibración de probabilidades mediante regresión de Platt (ECE de 0,279 a 0,006) y dos defectos del pipeline de datos descubiertos en operación gracias a contratos de validación bloqueantes. El sistema se despliega sobre una arquitectura *lakehouse* con modelado dimensional en estrella y un tablero analítico orientado a la decisión operativa. Los resultados indican que el modelo actúa principalmente como un prior geográfico-estacional modulado por la meteorología del día, conclusión que se cuantifica mediante análisis SHAP y ablación por bloques de variables.

**Palabras clave.** predicción de incendios; XGBoost; *Sparrow Search Algorithm*; calibración de probabilidades; FWI; arquitectura *lakehouse*; Región Pampeana.

## 1. Introducción

Los incendios de vegetación representan uno de los riesgos ambientales de mayor impacto en las regiones templadas productivas. En la Región Pampeana argentina, la combinación de pastizales naturales, rastrojos agrícolas y períodos de sequía genera condiciones propicias para igniciones que se propagan con rapidez, con consecuencias económicas y ecológicas significativas. La detección satelital de focos activos permite conocer dónde hay fuego una vez iniciado; la *anticipación* del riesgo, en cambio, requiere modelos predictivos capaces de estimar la probabilidad de ocurrencia con antelación suficiente para orientar la vigilancia y la asignación preventiva de recursos.

La literatura reciente ha demostrado la eficacia de los métodos de aprendizaje automático basados en árboles potenciados por gradiente para este problema. Wang *et al.* [1] integraron detecciones MODIS con variables meteorológicas, topográficas, de vegetación y antrópicas para la

provincia de Guangdong, y mostraron que un clasificador XGBoost [4] cuyos hiperparámetros se optimizan mediante el *Sparrow Search Algorithm* (SSA) [5] alcanza un desempeño superior al de configuraciones ajustadas manualmente, identificando la pendiente, la proximidad a caminos, la temperatura y la densidad de población entre los factores determinantes. De manera complementaria, los sistemas operativos de peligro de incendio se apoyan desde hace décadas en el *Canadian Forest Fire Weather Index System* (FWI) [2], un conjunto de índices acumulativos de humedad del combustible que ha sido adaptado a numerosas regiones fuera de Canadá mediante ajustes en sus tablas estacionales [3].

El presente trabajo adapta el marco de Wang *et al.* a un contexto operativo distinto en tres aspectos. Primero, el dominio corresponde a pastizales y agroecosistemas del hemisferio sur, lo que exige revisar los supuestos estacionales del FWI. Segundo, el objetivo no se limita al ajuste de un clasificador sino a la construcción de un sistema de producción completo, desde la ingesta diaria de datos hasta un tablero de decisión, sobre una arquitectura *lakehouse* [10] con garantías de calidad de datos. Tercero, el desarrollo se condujo bajo un criterio de auditoría permanente en el que cada iteración del modelo fue examinada en busca de fugas de información y desalineamientos entre entrenamiento y servicio, y en el que las métricas publicadas corresponden exclusivamente a la evaluación limpia posterior a dichas correcciones.

Las contribuciones principales son las siguientes. (i) Un dataset diario de riesgo de incendio para la Región Pampeana que integra cinco fuentes satelitales y meteorológicas sobre una grilla regular, con el sistema FWI calculado secuencialmente y adaptado al hemisferio sur. (ii) Un clasificador XGBoost–SSA evaluado con protocolo estricto de división temporal, contrastado contra líneas de base no triviales y analizado mediante SHAP, ablación por bloques y curvas de degradación por horizonte de pronóstico. (iii) La recalibración de las probabilidades del modelo mediante regresión de Platt, requisito para que el valor publicado al usuario final admita una lectura frecuentista. (iv) Una arquitectura de datos de tipo *medallion* con contratos de validación bloqueantes cuya utilidad se demostró empíricamente al detectar dos defectos latentes durante la puesta en producción. (v) Un registro transparente de la evolución del modelo a lo largo de cuatro versiones, incluyendo las fugas de información detectadas y el efecto de su corrección sobre las métricas.

El resto del documento se organiza como sigue. La Sección 2 describe el área de estudio, las fuentes y la variable objetivo. La Sección 3 presenta la arquitectura de datos. La Sección 4 detalla la metodología de modelado y evaluación. La Sección 5 documenta la evolución del modelo y los defectos corregidos. La Sección 6 reporta los resultados. La Sección 7 describe el despliegue operativo, y las Secciones 8 y 9 discuten limitaciones y conclusiones.

## 2. Área de estudio y datos

### 2.1. Área de estudio y unidad de análisis

El dominio espacial abarca la Región Pampeana y su periferia inmediata, entre los paralelos 28°S y 42°S y los meridianos 56°O y 68°O. Sobre ese recuadro se definió una grilla regular de  $0,25^\circ \times 0,25^\circ$  (aproximadamente 25 km), de la cual se retuvieron **2.266 celdas válidas** tras aplicar una máscara de tierra firme. Cada celda fue clasificada en una de nueve subregiones agroecológicas (Pampa Ondulada, Pampa Deprimida, Espinal, Chaco Húmedo, Chaco Seco, Monte, Delta/Litoral, entre otras) mediante criterios geográficos. La unidad de observación es el par celda–día y el período de estudio comprende del 1 de enero de 2022 al 31 de diciembre de 2024, lo que produce aproximadamente 2,5 millones de observaciones.

### 2.2. Variable objetivo

La variable dependiente es binaria e indica la ocurrencia de al menos una detección satelital de fuego en vegetación dentro de la celda durante el día. Se construyó a partir del producto de fuego

activo VIIRS de 375 m distribuido por NASA FIRMS [12, 11], reteniendo únicamente detecciones con nivel de confianza nominal o alto y tipo correspondiente a vegetación, con el fin de excluir falsas alarmas de origen industrial o reflectivo. Tras la deduplicación y la asignación de cada foco a su celda más cercana, la prevalencia global resulta cercana al 3 % de los pares celda-día, con fuerte estacionalidad concentrada entre julio y diciembre.

### 2.3. Fuentes de datos

La Tabla 1 resume las fuentes integradas. La base climática del entrenamiento proviene del reanálisis ERA5-Land [13], extraído mediante Google Earth Engine con agregación diaria por celda. Para la operación diaria se emplea el servicio Open-Meteo, que provee pronóstico a cuatro días junto con una ventana histórica reciente. La decisión de utilizar dos proveedores obedece a que el reanálisis ofrece profundidad y consistencia histórica para entrenar, mientras que el pronóstico operativo requiere disponibilidad diaria y gratuita; la homogeneización de esquemas entre ambos se resuelve en la capa de transformación y se valida antes de cada inferencia.

| Fuente          | Producto                  | Resolución    | Rol                   |
|-----------------|---------------------------|---------------|-----------------------|
| NASA FIRMS      | VIIRS 375 m fuego activo  | diaria        | variable objetivo     |
| ERA5-Land (GEE) | reanálisis meteorológico  | diaria, ~9 km | clima (entrenamiento) |
| Open-Meteo      | pronóstico + histórico    | diaria        | clima (operación)     |
| MODIS MOD13A2   | NDVI compuesto 16 días    | 1 km          | vegetación            |
| MODIS MCD12Q1   | cobertura del suelo anual | 500 m         | cobertura             |
| OpenStreetMap   | red vial                  | estática      | distancia a caminos   |
| WorldPop        | densidad de población     | estática      | presión antrópica     |

**Tabla 1:** Fuentes de datos integradas. Las variables estáticas se precalcularon por celda en una grilla auxiliar junto con la topografía (elevación, pendiente y orientación).

### 2.4. Variables predictoras

El modelo final emplea 39 variables organizadas en siete bloques (Tabla 2). El NDVI de frecuencia 16 días se llevó a frecuencia diaria mediante propagación del último valor disponible, y su anomalía se calculó respecto de la media histórica de cada celda, utilizando exclusivamente el período de entrenamiento para estimar dichas medias, que se persisten junto al modelo para garantizar consistencia en servicio. Las variables de autocorrelación espacial siguen el criterio de contigüidad de reina sobre las ocho celdas vecinas, e incluyen el promedio y el máximo del FWI del vecindario, así como un indicador de ocurrencia de fuego en el vecindario durante los tres días previos con ventana estrictamente retrospectiva.


| Bloque         | Variables                                                                                                                                              | N         |
|----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| Estáticas      | subregión, elevación, pendiente, orientación, dist. a caminos, densidad poblacional, cobertura                                                         | 7         |
| Meteorología   | temperatura, HR, viento, precipitación, radiación, humedad de suelo (2 capas), VPD, días secos, z-score de precipitación 90 d, medias móviles 30 d (2) | 12        |
| Sistema FWI    | FFMC, DMC, ISI, BUI, FWI, medias móviles 14/30 d                                                                                                       | 7         |
| Vegetación     | NDVI, anomalía de NDVI por celda                                                                                                                       | 2         |
| Estacionalidad | sen/cos de mes y día del año, calendario agrícola                                                                                                      | 5         |
| Interacciones  | FWI×VPD, temp.×días secos, viento×FWI                                                                                                                  | 3         |
| Espaciales     | FWI vecinal (media, máx.), fuego vecinal 3 días                                                                                                        | 3         |
| <b>Total</b>   |                                                                                                                                                        | <b>39</b> |

**Tabla 2:** Bloques de variables predictoras del modelo final. La partición en bloques es la utilizada en el análisis de ablación de la Sección 6.3.

### 3. Arquitectura del sistema de datos

#### 3.1. Pipeline *medallion*

El sistema se implementó sobre Databricks siguiendo el patrón *lakehouse* [10] con arquitectura *medallion* de cuatro capas (Figura 1). La capa *landing* recibe los archivos crudos de cada fuente en volúmenes de Unity Catalog. La capa *bronze* realiza la ingesta incremental mediante Auto Loader con puntos de control idempotentes, preservando metadatos de linaje (archivo de origen y marca temporal de ingesta). La capa *silver* aplica la limpieza tipada por fuente, y la capa *gold* materializa los datasets de consumo tanto para el entrenamiento como para la inferencia diaria y la capa analítica.



**Figura 1:** Arquitectura *medallion* sobre Databricks con Unity Catalog y tablas Delta. El mismo pipeline sirve al entrenamiento (histórico 2022–2024) y a la operación diaria (ventana de 35 días observados más 4 de pronóstico).

#### 3.2. Estándares y contratos de la capa *silver*

La capa *silver* se ajustó a prácticas estándar de la industria. Las tablas siguen la convención de nombres `silver_<fuente>`, se deduplican por clave natural (celda y fecha) y aplican recortes de dominio físico, dado que los proveedores producen ocasionalmente valores imposibles por artefactos de agregación, tales como precipitaciones de  $-0,00$  mm, humedades relativas superiores al 100 % o valores de NDVI fuera del intervalo  $[-1, 1]$ . Todas las tablas incorporan una columna de linaje con la marca temporal de procesamiento.

Además de la auditoría descriptiva posterior a la carga, la transformación diaria incorpora **contratos de datos bloqueantes** que se verifican antes de cada escritura. Se exige la completitud de nodos respecto de la grilla de referencia, la unicidad de la clave natural, la pertenencia de las variables a sus rangos físicos, la ausencia de valores nulos en los índices FWI y una profundidad mínima de la ventana histórica. Cuando un contrato falla, la tarea aborta con un mensaje diagnóstico y las etapas posteriores no se ejecutan, de modo que un dato defectuoso no puede propagarse hasta las predicciones publicadas. La Sección 5.3 documenta dos defectos reales que este mecanismo permitió detectar y que habrían pasado inadvertidos bajo un esquema de auditoría puramente descriptiva.

#### 3.3. Capa *gold* con doble modelado


La capa *gold* combina dos representaciones complementarias. Para el aprendizaje automático se materializan tablas anchas de tipo *one big table*, una para el entrenamiento histórico y otra para la inferencia diaria, en las que cada fila constituye un ejemplo con las 39 variables listas para el clasificador. Esta representación es la interfaz natural de un modelo de árboles potenciados y su contenido queda ligado al modelo por la suma de verificación del dataset.

Para el consumo analítico se agregó un **esquema en estrella** conforme a la metodología dimensional de Kimball [9], ilustrado en la Figura 2 y descrito en la Tabla 3. El hecho central registra las predicciones con grano celda por fecha de pronóstico por corrida, lo que otorga idempotencia a la inferencia diaria y conserva el historial de corridas. Las dimensiones concentran los atributos descriptivos y evitan su repetición en los hechos. Dos hechos secundarios registran la meteorología diaria y las detecciones históricas de fuego, y dos tablas auxiliares exponen la importancia de variables y las métricas de líneas de base para la página analítica del tablero. La

integridad referencial entre dimensiones y hechos se verifica mediante aserciones en cada corrida, dado que el formato de tablas subyacente no la impone por sí mismo. Se optó deliberadamente por mantener ambas representaciones en lugar de reemplazar una por otra, puesto que sirven a consumidores con ciclos de vida distintos; la tabla ancha es el contrato del modelo y la estrella es el contrato del tablero.

| Tabla                   | Grano                           | Fuente                      |
|-------------------------|---------------------------------|-----------------------------|
| dim_cell                | celda de grilla                 | grilla auxiliar + cobertura |
| dim_date                | día calendario 2022–2027        | generada                    |
| dim_model               | versión de modelo               | artefactos de evaluación    |
| fact_prediction         | celda × fecha pron. × corrida   | motor de inferencia         |
| fact_weather_daily      | celda × día (35 obs. + 4 pron.) | silver_openmeteo            |
| fact_fire_detection     | celda × día con focos           | silver_nasa_firms           |
| fact_feature_importance | variable × modelo               | análisis SHAP               |
| fact_baseline_metrics   | línea de base × modelo          | evaluación                  |

**Tabla 3:** Esquema en estrella de la capa de presentación. Dos vistas (`vw_predictions_latest`, `vw_fire_history`) resuelven las uniones habituales para el tablero.



**Figura 2:** Esquema en estrella de la capa de presentación. El hecho central `fact_prediction` irradia hacia las puntas de la estrella; las puntas superiores son las dimensiones y las inferiores los hechos secundarios, que comparten `dim_cell` y `dim_date` (relaciones punteadas). Se omiten las tablas de importancia y de líneas de base, relacionadas únicamente con `dim_model`.

### 3.4. Orquestación

Un *job* diario de Databricks sobre cómputo *serverless*, programado a las 06:00 UTC, encadena siete tareas. Las dos primeras extraen de Open-Meteo el pronóstico a cuatro días y la ventana histórica de 35 días. Las siguientes realizan la ingesta a *bronze*, la transformación *silver* con sus contratos, la construcción de la tabla de inferencia con las 39 variables alineadas al entrenamiento, la inferencia propiamente dicha y el refresco del esquema en estrella. La inferencia es idempotente por corrida, en el sentido de que una reejecución dentro del mismo día reemplaza la corrida previa en lugar de duplicarla.

## 4. Metodología

### 4.1. Sistema FWI adaptado al hemisferio sur

El sistema FWI [2] modela la humedad de tres estratos de combustible mediante los códigos FFMFC, DMC y DC, de los que derivan los índices de propagación ISI, de combustible disponible

BUI y el índice integrado FWI. El cálculo es secuencial por celda, dado que el estado de cada día depende del anterior, y se implementó en un módulo compartido por el entrenamiento y la operación para garantizar la identidad de ambas trayectorias.

La adaptación al hemisferio sur exigió desplazar seis meses las tablas estacionales de longitud efectiva del día, siguiendo los valores publicados para latitudes de 30–40°S [3]. Durante el desarrollo se detectó que una versión previa empleaba por error la tabla  $L_f$  del código DC, que toma valores negativos en invierno, para el cálculo del DMC, lo que colapsaba dicho código durante todo el invierno austral en contradicción con la física del modelo; la versión corregida emplea la tabla  $L_e$  correspondiente, de valores siempre positivos. Dado que los códigos DMC y DC convergen lentamente desde sus valores iniciales convencionales (FFMC 85, DMC 6, DC 15), el entrenamiento descarta las primeras ocho semanas del período como fase de estabilización, y la operación diaria garantiza la continuidad del cálculo manteniendo una ventana histórica deslizante de 35 días previa al pronóstico.

## 4.2. Diseño experimental

La evaluación adopta una división temporal estricta en tres particiones. El conjunto de entrenamiento comprende desde marzo de 2022 hasta abril de 2024 y se balancea a razón 1:1 mediante submuestreo estratificado por subregión, lo que produce 81.212 ejemplos. El conjunto de validación cubre mayo y junio de 2024 con su distribución natural (137.921 observaciones) y se emplea para la detención temprana, la calibración y la selección de umbrales. El conjunto de prueba, estrictamente posterior, abarca de julio a diciembre de 2024 (416.024 observaciones, prevalencia 3,13 %) y coincide con la temporada de fuego; ninguna decisión de modelado se tomó con información de esta partición. La reproducibilidad se asegura persistiendo la suma MD5 del dataset y la semilla aleatoria junto con las métricas, y la suite de evaluación verifica en cada ejecución que el modelo publicado reproduce el AUC de referencia con deriva nula.

El balanceo del entrenamiento responde a la baja prevalencia del fenómeno, pero introduce una distorsión conocida en las probabilidades del modelo, que quedan referidas a un universo con prevalencia artificial del 50 %. La Sección 4.4 trata la corrección de este efecto, y se señala asimismo que la métrica AP utilizada durante la búsqueda de hiperparámetros, calculada por validación cruzada sobre el conjunto balanceado, opera en ese universo distorsionado y no es comparable con el AP reportado sobre el conjunto de prueba.

## 4.3. Optimización de hiperparámetros mediante SSA

El *Sparrow Search Algorithm* [5] es un metaheurístico poblacional inspirado en el comportamiento de forrajeo y vigilancia de los gorriones, en el que la población se divide en productores, que exploran el espacio de búsqueda, y rastreadores, que explotan las mejores soluciones, con un subconjunto de individuos centinela que introduce perturbaciones ante el riesgo de estancamiento. Siguiendo a Wang *et al.*, se empleó SSA para optimizar ocho hiperparámetros de XGBoost, con una población de 15 individuos y 15 iteraciones, deteniendo la búsqueda ante ausencia de mejora sostenida. La función objetivo fue la precisión media obtenida por validación cruzada de tres particiones sobre el conjunto de entrenamiento balanceado. La configuración resultante se reporta en la Tabla 4; el modelo final emplea 237 árboles seleccionados por detención temprana sobre la partición de validación.



| Hiperparámetro                     | Valor  |
|------------------------------------|--------|
| Profundidad máxima                 | 8      |
| Tasa de aprendizaje                | 0,0519 |
| Submuestreo de filas               | 0,791  |
| Submuestreo de columnas            | 0,840  |
| Peso mínimo por hoja               | 6      |
| $\gamma$ (poda)                    | 1,447  |
| Regularización $L_1$ ( $\alpha$ )  | 3,024  |
| Regularización $L_2$ ( $\lambda$ ) | 1,399  |
| Árboles (detención temprana)       | 237    |

**Tabla 4:** Hiperparámetros del modelo final obtenidos por SSA (15 individuos, 15 iteraciones, validación cruzada de 3 particiones sobre el conjunto balanceado).

#### 4.4. Calibración de probabilidades

Un sistema de alerta que publica probabilidades debe garantizar que estas admitan lectura frecuentista, esto es, que entre los casos a los que asigna un valor  $p$  la fracción observada de positivos sea aproximadamente  $p$ . La desviación se cuantifica mediante el error de calibración esperado,

$$\text{ECE} = \sum_{b=1}^B \frac{n_b}{N} |\bar{p}_b - \bar{y}_b|, \quad (1)$$

donde la predicción se particiona en  $B$  intervalos de igual población,  $\bar{p}_b$  es la probabilidad media predicha en el intervalo  $b$  y  $\bar{y}_b$  la fracción de positivos observada. El modelo crudo presenta un ECE de 0,279 sobre el conjunto de prueba, consecuencia directa del entrenamiento balanceado descrito en la Sección 4.2; cuando el modelo predice un 60 % la frecuencia observada ronda el 5 %.

Se compararon dos correctores ajustados sobre la partición de validación. La regresión isotónica [7] y el escalado de Platt [6], que ajusta una transformación sigmoidea

$$\hat{p} = \sigma(a \cdot \text{logit}(p) + b), \quad (2)$$

con  $a$  y  $b$  estimados por máxima verosimilitud. Ambos reducen el ECE en dos órdenes de magnitud, pero la isotónica, al ser una función escalonada, empata bloques de puntuaciones y degrada la precisión media de 0,304 a 0,284, mientras que la transformación de Platt es estrictamente monótona y preserva el ordenamiento de manera exacta, con AUC y AP idénticos al modelo crudo. Se adoptó por lo tanto el escalado de Platt, con un ECE final de 0,006. En servicio, el corrector se evalúa a partir de sus coeficientes serializados en un archivo de texto, evitando la deserialización de objetos dependientes de versiones de biblioteca en el entorno de inferencia.

El umbral operativo se rederivó sobre las probabilidades calibradas maximizando la medida  $F_\beta$  con  $\beta = 2$  en validación, elección que prioriza la exhaustividad por sobre la precisión en atención a la asimetría de costos del dominio, donde omitir un fuego real resulta más costoso que emitir una falsa alarma. El umbral resultante es  $\tau = 0,070$ , con exhaustividad de 0,634 y precisión de 0,218 sobre el conjunto de prueba.

#### 4.5. Protocolo de evaluación

El desempeño se contrasta contra tres líneas de base. La primera predice constantemente la prevalencia. La segunda es la persistencia espacial, que asigna riesgo positivo a las celdas con fuego observado en los tres días previos, y constituye el competidor natural de un sistema de vigilancia. La tercera es un XGBoost entrenado únicamente con el índice FWI, que representa

la práctica operativa tradicional basada en peligro meteorológico. La interpretación del modelo emplea valores SHAP [8] en lugar de la importancia por ganancia del propio XGBoost, cuyo sesgo hacia variables de corte frecuente se discute en la Sección 6.3, y se complementa con una ablación por bloques que reentrena el modelo excluyendo cada grupo de la Tabla 2. Finalmente, se cuantifica la degradación por horizonte de pronóstico simulando el estado real de servicio, en el que el indicador de fuego vecinal no es observable para horizontes mayores a un día, y se examina la heterogeneidad espacial del error por subregión.

## 5. Evolución del modelo y defectos corregidos

El desarrollo atravesó cuatro versiones del modelo y dos auditorías integrales del código, una durante el desarrollo y otra previa a la puesta en producción. Esta sección documenta ese recorrido, en el entendimiento de que la transparencia sobre los errores cometidos y corregidos forma parte del rigor metodológico del trabajo.

### 5.1. De la línea de base al modelo final

La Tabla 5 resume las cuatro iteraciones. La primera versión entrenó sobre la distribución natural sin balanceo y con una búsqueda de hiperparámetros preliminar; con el umbral elegido alcanzaba una exhaustividad de 0,965 a costa de una precisión del 3 %, es decir, alertaba sobre la práctica totalidad de la región, comportamiento inútil a efectos operativos. La segunda versión introdujo el balanceo 1:1 estratificado por subregión, la optimización SSA completa y las variables de interacción, elevando la precisión media de 0,181 a 0,295. La tercera versión refinó la detención temprana y la infraestructura de entrenamiento, alcanzando una precisión media de 0,315. La cuarta versión incorporó las variables de autocorrelación espacial y, de manera decisiva, corrigió las fugas de información descritas a continuación, por lo que sus métricas son las únicas directamente comparables con un despliegue real.

| Versión | Cambios principales                        | Estado        | AUC          | AP           |
|---------|--------------------------------------------|---------------|--------------|--------------|
| v1      | sin balanceo, SSA preliminar               | con fugas     | 0,863        | 0,181        |
| v2      | balanceo 1:1, SSA completo, interacciones  | con fugas     | 0,893        | 0,295        |
| v3      | detención temprana con paciencia, refactor | con fugas     | 0,898        | 0,315        |
| v4      | variables espaciales, corrección de fugas  | <b>limpio</b> | <b>0,897</b> | <b>0,304</b> |

**Tabla 5:** Evolución del modelo. Las métricas de v1–v3 están infladas por las fugas de información posteriormente detectadas y no son comparables entre sí en sentido estricto; se reportan como registro del proceso. El AUC de v4 es marginalmente inferior al de v3 precisamente porque elimina información ilegítima.

### 5.2. Fugas de información detectadas y corregidas

La auditoría del código de entrenamiento identificó tres mecanismos de fuga de información, todos corregidos en la versión final.

La primera fuga afectaba a la anomalía de NDVI, que se calculaba como desviación respecto de la media de cada celda computada sobre el *dataset completo*, incluyendo los períodos de validación y prueba. La corrección restringe el cálculo de las medias al período de entrenamiento y las persiste como artefacto del modelo, de modo que el servicio utilice exactamente los mismos valores.

La segunda fuga consistía en emplear el conjunto de prueba como conjunto de evaluación para la detención temprana del entrenamiento, práctica que selecciona implícitamente el número de árboles que maximiza el desempeño en prueba. La corrección introduce la partición de validación intermedia descrita en la Sección 4.2, reservando la prueba para un único uso final.



La tercera fuga involucraba al indicador de fuego vecinal, cuya ventana temporal incluía el propio día de la predicción, con lo cual la variable incorporaba información contemporánea al evento que se pretendía predecir. La corrección impone una ventana estrictamente retrospectiva sobre los tres días previos, idéntica en entrenamiento y servicio.

El efecto conjunto de estas correcciones se aprecia en la Tabla 5. El AUC desciende de 0,898 a 0,897 y la precisión media de 0,315 a 0,304 al pasar de la versión con fugas a la versión limpia, a pesar de que esta última agrega variables espaciales de valor genuino. La magnitud moderada del descenso indica que las fugas inflaban las métricas de manera perceptible pero no dominante; su corrección importa menos por el tamaño del ajuste que por la validez de las cifras publicadas.

### 5.3. Defectos del pipeline detectados en operación

Dos defectos adicionales emergieron durante la puesta en producción del pipeline diario, y su detección ilustra el valor de los contratos de datos de la Sección 3.2.

El primero afectaba a la ventana histórica meteorológica. El extractor del histórico estaba concebido para ejecutarse una única vez en la inicialización del sistema, mientras que la retención de la capa *bronze* eliminaba diariamente los registros con antigüedad mayor a 35 días. En consecuencia, la ventana se acortaba un día por cada jornada de operación hasta vaciarse por completo, dejando al cálculo del FWI sin fase de estabilización, todo ello mientras cada tarea del pipeline reportaba ejecución exitosa. El defecto se detectó al verificar los conteos del esquema en estrella, cuya tabla de hechos meteorológicos contenía únicamente los cuatro días de pronóstico. La corrección convirtió la extracción del histórico en una operación diaria que reconstruye la ventana completa, y añadió al contrato de la capa *silver* la exigencia de una profundidad histórica mínima, de manera que una regresión futura de este tipo aborta el pipeline en lugar de degradar silenciosamente las predicciones.

El segundo defecto residía en la implementación del índice BUI. Ante valores simultáneamente bajos de los códigos DMC y DC, situación característica del invierno austral con precipitación intensa y bajas temperaturas, la segunda rama de la ecuación del BUI produce valores negativos, y la potencia fraccionaria  $BUI^{0,809}$  del cálculo posterior del FWI degenera entonces en un valor indefinido. La implementación de referencia del sistema canadiense acota el BUI inferiormente en cero, salvaguarda que faltaba en la implementación propia y que se incorporó en el módulo compartido. Cabe señalar que el defecto permaneció latente durante todo el entrenamiento, dado que las secuencias meteorológicas del período histórico no alcanzaron la región crítica del espacio de estados, y se manifestó recién ante la primera ventana operativa de invierno con datos reales completos, donde fue interceptado por el contrato que exige la no nulidad de los índices FWI.


## 6. Resultados

### 6.1. Desempeño global y comparación con líneas de base

Sobre el conjunto de prueba, el modelo final alcanza un AUC-ROC de 0,8965 y una precisión media de 0,3038. La Tabla 6 sitúa estas cifras en contexto. La persistencia espacial, competidor serio en un fenómeno con fuerte autocorrelación, obtiene una precisión media de 0,125, por lo que el modelo la multiplica por 2,4. El modelo entrenado únicamente con el índice FWI apenas supera a la predicción por prevalencia (0,035 frente a 0,031), resultado que merece subrayarse por su implicancia operativa. El índice de peligro meteorológico estándar de la disciplina, empleado de manera aislada, carece de capacidad discriminante sobre *dónde* ocurrirá el fuego en la región de estudio; su información es predominantemente temporal, mientras que la señal espacial reside en la geografía y la presión antrópica.

| Modelo                             | AUC          | AP           |
|------------------------------------|--------------|--------------|
| Prevalencia constante              | 0,500        | 0,031        |
| Solo FWI (XGBoost univariado)      | 0,552        | 0,035        |
| Persistencia espacial (3 días)     | 0,719        | 0,125        |
| <b>Modelo final (39 variables)</b> | <b>0,897</b> | <b>0,304</b> |

**Tabla 6:** Comparación contra líneas de base sobre el conjunto de prueba (416.024 observaciones, prevalencia 3,13 %).




**Figura 3:** Suite de evaluación del modelo final. Arriba a la izquierda, curva de fiabilidad del modelo sin calibrar (ECE 0,279), que motiva la corrección de la Sección 4.4. Arriba a la derecha, precisión media contra líneas de base. Abajo a la izquierda, ablación por bloques ( $\Delta$ AP al excluir cada bloque). Abajo a la derecha, AUC por subregión.

## 6.2. Calibración

La Figura 4 muestra la curva de fiabilidad tras aplicar el escalado de Platt. El ECE desciende de 0,279 a 0,0056 sin alteración alguna del ordenamiento, conforme a lo discutido en la Sección 4.4, y la comparación con la regresión isotónica (Tabla 7) fundamenta la elección del método. Tras la calibración, la probabilidad publicada por el sistema admite lectura directa; un valor del 5 % corresponde a una frecuencia observada cercana al 5 %.

| Corrector               | ECE val.    | ECE prueba    | AUC           | AP            |
|-------------------------|-------------|---------------|---------------|---------------|
| Sin calibrar            | 0,191       | 0,279         | 0,8965        | 0,3038        |
| Regresión isotónica     | $\approx 0$ | 0,0061        | 0,8959        | 0,2838        |
| <b>Platt (adoptado)</b> | 0,0007      | <b>0,0056</b> | <b>0,8965</b> | <b>0,3038</b> |

**Tabla 7:** Comparación de correctores de calibración ajustados sobre validación y evaluados sobre prueba. La transformación de Platt corrige el ECE preservando el ordenamiento de manera exacta.



**Figura 4:** Curva de fiabilidad tras el escalado de Platt. La probabilidad predicha coincide con la frecuencia observada a lo largo de todo el rango.

### 6.3. Importancia de variables y ablación por bloques

La importancia por ganancia del propio XGBoost atribuía el 73 % del total al indicador de fuego vecinal, lectura que sugería un modelo de puro contagio espacial. El análisis SHAP corrige sustancialmente esa interpretación (Tabla 8). El indicador vecinal conserva el primer puesto pero con un peso comparable al de la elevación, y el grueso de la contribución se distribuye entre las variables estáticas, la radiación solar y la estacionalidad. La discrepancia entre ambos rankings ilustra el sesgo conocido de la importancia por ganancia hacia variables utilizadas en cortes tempranos y frecuentes, y justifica la adopción de SHAP como criterio interpretativo del sistema.

| #  | Variable               | SHAP $\overline{ v }$ | Ganancia |
|----|------------------------|-----------------------|----------|
| 1  | fuego vecinal 3 días   | 0,522                 | 0,733    |
| 2  | elevación              | 0,498                 | 0,021    |
| 3  | densidad de población  | 0,326                 | 0,012    |
| 4  | radiación solar        | 0,320                 | 0,008    |
| 5  | coseno del día del año | 0,273                 | 0,006    |
| 6  | subregión              | 0,262                 | 0,025    |
| 7  | anomalía de NDVI       | 0,164                 | 0,006    |
| 8  | FFMC                   | 0,119                 | 0,018    |
| 9  | precipitación          | 0,112                 | 0,011    |
| 10 | NDVI                   | 0,107                 | 0,005    |

**Tabla 8:** Diez variables de mayor importancia según el valor SHAP medio absoluto, contrastadas con la importancia por ganancia. El contraste entre columnas evidencia el sesgo de la ganancia hacia la variable dominante en los cortes.

La ablación por bloques (Figura 3, panel inferior izquierdo) confirma la lectura anterior. La exclusión del bloque estático produce la mayor pérdida, de 0,074 puntos de precisión media, seguida por la meteorología (0,026) y la estacionalidad (0,014). La exclusión del bloque FWI resulta neutra (variación de +0,0004), lo que indica que los índices, en presencia de las variables meteorológicas crudas de las que derivan, no aportan información adicional al clasificador; se conservan en el sistema por su valor interpretativo para el usuario operativo y por comparabilidad con la literatura, decisión que se explicita en lugar de ocultarse. La exclusión de las interacciones mejora marginalmente el desempeño (+0,003), hallazgo que se registró sin reentrenar el modelo publicado, dado que la ganancia es de magnitud comparable al ruido de estimación y el reentrenamiento invalidaría la trazabilidad de los artefactos evaluados.

En conjunto, estos análisis permiten caracterizar con precisión la naturaleza del modelo. Se trata ante todo de un **prior geográfico-estacional**, que aprende dónde y en qué época del año se concentra históricamente el fuego, modulado en el margen por la meteorología del día. Esta caracterización no disminuye su utilidad, puesto que dicho prior está lejos de ser trivial, como demuestra la ventaja de 2,4 veces sobre la persistencia, pero sí delimita su alcance. El sistema prioriza la vigilancia; no pronostica igniciones individuales.

#### 6.4. Degradación por horizonte de pronóstico

El indicador de fuego vecinal solo es observable para el primer día de pronóstico, dado que para horizontes mayores los tres días previos aún no han ocurrido y la variable toma el valor nulo en servicio. La Tabla 9 cuantifica el costo de esta pérdida mediante simulación del estado real de servicio sobre el conjunto de prueba. El modelo desplegado con la variable anulada pierde 0,026 puntos de precisión media, y un modelo reentrenado sin la variable, que representa el techo alcanzable para horizontes largos, pierde 0,007. La degradación es moderada, pues la señal se solapa con el resto del bloque espacial y con el prior geográfico, pero existe, y el tablero la comunica distinguiendo el primer día de los siguientes.

| Escenario                                         | AUC    | AP     |
|---------------------------------------------------|--------|--------|
| Horizonte 1 (variable observada)                  | 0,8965 | 0,3038 |
| Horizonte $\geq 2$ (modelo actual, variable nula) | 0,8879 | 0,2778 |
| Reentrenado sin la variable (techo honesto)       | 0,8939 | 0,2969 |

**Tabla 9:** Degradación por horizonte de pronóstico, medida sobre el conjunto de prueba simulando el estado de la variable espacial en servicio.

## 6.5. Heterogeneidad espacial del error

El AUC por subregión se mantiene entre 0,80 y 0,90 en las ocho subregiones con casos suficientes (Figura 3, panel inferior derecho), sin que el desempeño se concentre en las zonas de alta ocurrencia. La precisión media sí varía sustancialmente con la prevalencia local, desde 0,078 en la subregión de menor tasa de fuego hasta 0,428 en la de mayor, comportamiento esperable en una métrica sensible a la prevalencia y que no compromete la utilidad comparativa del ranking dentro de cada día.

## 7. Despliegue operativo

### 7.1. Presentación del riesgo fuera de temporada


El umbral operativo se calibró sobre la temporada de fuego, de modo que durante el invierno austral el modelo produce probabilidades honestas de entre 0 y 2 % y ninguna alerta, lo que plantearía un tablero visualmente vacío. Se evaluaron cuatro alternativas de presentación. La reducción estacional del umbral se descartó por indefendible, dado que generaría alertas que el modelo no respalda. La opción de un modo demostrativo con fechas de temporada alta se descartó por introducir ambigüedad sobre la vigencia de los datos. Se adoptó una combinación de honestidad absoluta y lectura relativa. Cada predicción publica, junto a la probabilidad calibrada, su **percentil dentro del día**, definido como

$$\text{pct}_{i,t} = \frac{100}{N} \text{rank}(\hat{p}_{i,t}) \quad \text{con } N = 2,266, \quad (3)$$

junto con una categoría ordinal derivada. El mapa del tablero colorea por percentil, lo que preserva la visibilidad del gradiente espacial durante todo el año, mientras que la probabilidad absoluta y la ausencia de alertas se muestran sin alteración y una nota explica la estacionalidad. La solución no modifica el modelo, las métricas ni el umbral, pues opera exclusivamente en la capa de presentación.

### 7.2. Tablero analítico

El tablero se implementó como *dashboard* AI/BI nativo de Databricks sobre el esquema en estrella, en lugar del *frontend* web con API intermedia considerado inicialmente. La alternativa adoptada no requiere infraestructura adicional, hereda la gobernanza del catálogo y se refresca automáticamente con cada corrida del *job*. Su diseño siguió un criterio de orientación a la decisión, en el que cada página responde una pregunta operativa concreta. La primera página responde dónde concentrar la vigilancia hoy, mediante indicadores sintéticos, el mapa de percentiles y una tabla de las quince celdas de mayor probabilidad acompañadas de las condiciones que explican cada caso. La segunda página responde si el riesgo mejora o empeora, con la evolución del pronóstico a cuatro días y las subregiones de mayor variación. La tercera contextualiza el presente contra el registro histórico de detecciones 2022–2024, y la cuarta expone las métricas reales del modelo, la importancia SHAP y la comparación con las líneas de base, incorporando las limitaciones como parte de la interfaz.



**Figura 5:** Página principal del tablero operativo. Los indicadores sintetizan la situación del día, el mapa colorea las 2.266 celdas por percentil de riesgo relativo y la tabla detalla las quince celdas prioritarias con las condiciones meteorológicas que explican cada caso.



**Figura 6:** Página de tendencia del tablero. Evolución de la probabilidad media y máxima en la ventana de pronóstico, subregiones con mayor variación hacia el cuarto día y contexto meteorológico de la ventana de 39 días.





**Figura 7:** Página del modelo en el tablero. Las métricas de prueba, la importancia SHAP y la comparación contra líneas de base se exponen al usuario final como parte de la interfaz.

## 8. Discusión

**Elección del clasificador y del optimizador.** Los árboles potenciados por gradiente continúan siendo el método de referencia práctica para datos tabulares estructurados con interacciones no lineales y volúmenes moderados, y la adopción de SSA mantiene la comparabilidad con el marco de Wang *et al.* [1], cuyo aporte metodológico central reside precisamente en esa combinación. No se exploraron arquitecturas de aprendizaje profundo, dado que con aproximadamente 29.000 ejemplos positivos y variables tabulares la evidencia disponible no anticipaba beneficios que justificaran el costo experimental.

**Conservación del sistema FWI.** La ablación demuestra que los índices FWI no aportan capacidad predictiva en presencia de la meteorología cruda. Se conservan de todos modos en el sistema por tres razones. Constituyen el lenguaje operativo del dominio, habilitan la comparación con la literatura y su costo marginal de cómputo es nulo. La redundancia se documenta explícitamente en lugar de omitirse.

**Doble representación en la capa de consumo.** La coexistencia de la tabla ancha para el modelo y del esquema en estrella para el tablero responde a que ambos artefactos poseen consumidores y ciclos de vida distintos. La primera queda ligada al modelo mediante suma de verificación y garantiza reproducibilidad; el segundo evoluciona con las necesidades analíticas sin afectar al entrenamiento.

**Limitaciones.** El trabajo presenta limitaciones que conviene explicitar. El denominado z-score de precipitación de 90 días no constituye el índice SPI estándar de la Organización Meteorológica Mundial, que requiere una climatología de treinta años, y debe interpretarse como anomalía relativa dentro del período disponible. La serie histórica de tres años submuestra la variabilidad interanual asociada a ciclos ENSO y sequías plurianuales, y no se realizó validación cruzada de

ventanas deslizantes multianuales. La variable objetivo corresponde a detección satelital y no a ocurrencia verdadera, con los falsos negativos de etiqueta que la nubosidad y la geometría de pasada introducen. La resolución de  $0,25^\circ$  resulta adecuada para priorización regional pero insuficiente para despliegue táctico. El cálculo secuencial del FWI se ejecuta celda por celda en un único proceso, solución suficiente para el dominio actual que requeriría vectorización distribuida para dominios mayores. Finalmente, el horizonte operativo se limita a los cuatro días del proveedor de pronóstico, con la degradación cuantificada en la Sección 6.4.

## 9. Conclusiones

Este trabajo construyó y desplegó un sistema completo de predicción diaria de riesgo de incendio para la Región Pampeana, desde la ingesta de datos multi-fuente hasta un tablero de decisión operativa. El clasificador XGBoost optimizado por SSA alcanza un AUC de 0,897 y una precisión media de 0,304 sobre un conjunto de prueba temporal estricto, superando con holgura a la persistencia espacial y al índice FWI utilizado aisladamente. La recalibración mediante regresión de Platt reduce el error de calibración en dos órdenes de magnitud y convierte la salida del modelo en probabilidades interpretables, condición necesaria para cualquier sistema de alerta que aspire a la confianza de sus usuarios.

Más allá de las métricas, el trabajo aporta un registro metodológico que se considera su contribución principal. La documentación de cuatro versiones del modelo con sus fugas de información y el efecto de corregirlas, la caracterización del modelo como prior geográfico-estacional mediante SHAP y ablación, la cuantificación de la degradación por horizonte y la detección en operación de dos defectos latentes del pipeline mediante contratos de datos bloqueantes conforman, en conjunto, un argumento empírico a favor de la ingeniería rigurosa en sistemas de aprendizaje automático aplicado. Las líneas de trabajo futuro incluyen la validación cruzada temporal multianual a medida que se acumule historia, el reentrenamiento sin el bloque de interacciones, la incorporación de una climatología extendida para un índice de sequía estándar y el aumento de resolución espacial en las subregiones de mayor riesgo.

## Referencias

- [1] Wang, H.; Yu, C.; Wang, J. Spatial Prediction of Forest Fire Risk in Guangdong Province Using Multi-Source Geospatial Data and Sparrow Search Algorithm-Optimized XGBoost. *AppliedMath* **2026**, 6(1), 10.
- [2] Van Wagner, C. E. *Development and Structure of the Canadian Forest Fire Weather Index System*; Forestry Technical Report 35; Canadian Forestry Service. Ottawa, Canada, 1987.
- [3] Lawson, B. D.; Armitage, O. B. *Weather Guide for the Canadian Forest Fire Danger Rating System*; Natural Resources Canada, Canadian Forest Service. Edmonton, Canada, 2008.
- [4] Chen, T.; Guestrin, C. XGBoost: A Scalable Tree Boosting System. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, USA, 2016; pp. 785–794.
- [5] Xue, J.; Shen, B. A novel swarm intelligence optimization approach: sparrow search algorithm. *Systems Science & Control Engineering* **2020**, 8(1), 22–34.
- [6] Platt, J. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. *Advances in Large Margin Classifiers* **1999**, 10(3), 61–74.
- [7] Zadrozny, B.; Elkan, C. Transforming classifier scores into accurate multiclass probability estimates. En *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, Edmonton, Canada, 2002; pp. 694–699.

- [8] Lundberg, S. M.; Lee, S.-I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems* **2017**, 30, 4765–4774.
- [9] Kimball, R.; Ross, M. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3.1 ed.; Wiley. Indianapolis, USA, 2013.
- [10] Armbrust, M.; Ghodsi, A.; Xin, R.; Zaharia, M. Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics. En *Proceedings of the 11th Conference on Innovative Data Systems Research (CIDR)*, 2021.
- [11] Schroeder, W.; Oliva, P.; Giglio, L.; Csiszar, I. A. The New VIIRS 375 m active fire detection data product. *Remote Sensing of Environment* **2014**, 143, 85–96.
- [12] NASA FIRMS. *Fire Information for Resource Management System*. Disponible en <https://firms.modaps.eosdis.nasa.gov> (acceso julio de 2026).
- [13] Muñoz-Sabater, J.; *et al.* ERA5-Land: a state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data* **2021**, 13, 4349–4383.